

Rapport de TP : Architecture Big Data End-to-End

site ecom : <https://lumi-dun.vercel.app/>

1. Vue d'Ensemble de l'Architecture

L'objectif était de capturer les interactions utilisateurs sur un site E-commerce en temps réel, de les traiter via un cluster distribué et de les archiver dans un Data Lake.

1. **Source** : Application Node.js (Frontend/Backend) envoyant des événements JSON via kafka.js.
2. **Ingestion** : Apache Kafka sur une VM Google Cloud (Compute Engine).
3. **Traitement** : Cluster Google Cloud Dataproc (Spark Structured Streaming).
4. **Stockage** : Google Cloud Storage (Data Lake) au format Parquet.

[Capture d'écran suggérée : Schéma de l'architecture ou vue d'ensemble des instances sur la console GCP]

2. Niveau 1 : Ingestion avec Apache Kafka (GCP VM)

Installation et Configuration (VM Debian/Ubuntu)

Sur la VM Compute Engine, nous avons préparé l'environnement avec les commandes suivantes :

```
# 1. Installation de Java (Prérequis Kafka)
sudo apt update
sudo apt install default-jre -y

# 2. Téléchargement et extraction de Kafka
wget
[https://archive.apache.org/dist/kafka/3.5.0/kafka_2.12-3.5.0.tgz](https://
archive.apache.org/dist/kafka/3.5.0/kafka_2.12-3.5.0.tgz)
tar -xzf kafka_2.12-3.5.0.tgz
cd kafka_2.12-3.5.0

# 3. Configuration KRaft (Listeners Externes)
# Modifier config/kraft/server.properties :
# advertised.listeners=PLAINTEXT://34.78.144.120:9092
```

Commandes Opérationnelles

```
# Génération de lID de cluster et formatage
KAFKA_CLUSTER_ID=$(bin/kafka-storage.sh random-uuid)
bin/kafka-storage.sh format -t $KAFKA_CLUSTER_ID -c
config/kraft/server.properties

# Lancement du serveur en mode démon
bin/kafka-server-start.sh -daemon config/kraft/server.properties
```

Validation du flux JSON

Pour vérifier que le site e-commerce envoyait bien les données, nous avons utilisé le client console :

```
bin/kafka-console-consumer.sh --topic web-events --bootstrap-server
localhost:9092 --from-beginning
```



SSH dans votre navigateur

↑ IMPORTER UN FICHIER

↓ TÉLÉCHARGER LE FICHIER




```
": "1258cb0a-747b-40f1-ac51-ee9878ca03df", "name": "T-shirt Blanc", "url": "/", "id": "888798c3-1340-4ac4-90ad-6d96db931e84", "userId": null, "userAgent": "Mozilla/5.0 (Windows NT 10.0; Win64; x64; rv:146.0) Gecko/20100101 Firefox/146.0", "timestamp": "2026-01-02T19:01:07.562Z"}
{"guestId": "c8090655-7d0d-4c6f-b40b-bfd5b035517c", "type": "PAGE VIEW", "payload": {"page": "home"}, "url": "/", "id": "7071e1f6-f8b6-43be-8fe3-03ab4c04549d", "userId": null, "userAgent": "Mozilla/5.0 (Windows NT 10.0; Win64; x64; rv:146.0) Gecko/20100101 Firefox/146.0", "timestamp": "2026-01-02T19:01:22.001Z"}
{"guestId": "c8090655-7d0d-4c6f-b40b-bfd5b035517c", "type": "PRODUCT_CLICK", "payload": {"productId": "1258cb0a-747b-40f1-ac51-ee9878ca03df", "name": "T-shirt Blanc", "url": "/", "id": "989ef2bc-5cb9-443c-8d3a-41f2dlb35718", "userId": null, "userAgent": "Mozilla/5.0 (Windows NT 10.0; Win64; x64; rv:146.0) Gecko/20100101 Firefox/146.0", "timestamp": "2026-01-02T19:54:40.301Z"}
{"guestId": "c8090655-7d0d-4c6f-b40b-bfd5b035517c", "type": "CATEGORY_CLICK", "payload": {"category": "clothing", "url": "/", "id": "b924926a-971e-4f86-9300-7e12881e96b0", "userId": null, "userAgent": "Mozilla/5.0 (Windows NT 10.0; Win64; x64; rv:146.0) Gecko/20100101 Firefox/146.0", "timestamp": "2026-01-02T19:54:48.293Z"}
{"guestId": "c8090655-7d0d-4c6f-b40b-bfd5b035517c", "type": "SEARCH", "payload": {"query": "", "category": "clothing", "resultCount": 4, "url": "/results", "id": "3113722c-f944-4529-b404-8c2db2bf00c7", "userId": null, "userAgent": "Mozilla/5.0 (Windows NT 10.0; Win64; x64; rv:146.0) Gecko/20100101 Firefox/146.0", "timestamp": "2026-01-02T19:54:48.806Z"}
{"guestId": "c8090655-7d0d-4c6f-b40b-bfd5b035517c", "type": "PRODUCT_CLICK", "payload": {"productId": "b009fe72-31ed-47d3-8797-bfa6b5642569", "name": "Sweat à Capuche", "url": "/results", "id": "0776f271-e37e-452f-b650-1742bd4e72ed", "userId": null, "userAgent": "Mozilla/5.0 (Windows NT 10.0; Win64; x64; rv:146.0) Gecko/20100101 Firefox/146.0", "timestamp": "2026-01-02T19:54:50.336Z"}
{"guestId": "c8090655-7d0d-4c6f-b40b-bfd5b035517c", "type": "SEARCH", "payload": {"query": "", "category": "used", "resultCount": 2, "url": "/results", "id": "cb313792-9b68-476b-aec4-7be3612ef56d", "userId": null, "userAgent": "Mozilla/5.0 (Windows NT 10.0; Win64; x64; rv:146.0) Gecko/20100101 Firefox/146.0", "timestamp": "2026-01-02T19:54:55.965Z"}
{"guestId": "c8090655-7d0d-4c6f-b40b-bfd5b035517c", "type": "PRODUCT_CLICK", "payload": {"productId": "955e8da0-67ce-4d81-8a23-5be11121415d", "name": "Caméra Vintage", "url": "/results", "id": "7b0f523f-1662-427e-8746-20aac3595019", "userId": null, "userAgent": "Mozilla/5.0 (Windows NT 10.0; Win64; x64; rv:146.0) Gecko/20100101 Firefox/146.0", "timestamp": "2026-01-02T19:54:57.518Z"}
{"guestId": "c8090655-7d0d-4c6f-b40b-bfd5b035517c", "type": "PAGE_VIEW", "payload": {"page": "home"}, "url": "/", "id": "245739ca-beda-453b-b1d3-d1f72297274e", "userId": null, "userAgent": "Mozilla/5.0 (Windows NT 10.0; Win64; x64; rv:146.0) Gecko/20100101 Firefox/146.0", "timestamp": "2026-01-02T19:55:00.487Z"}
```

3. Niveau 2 : Intégration Backend (Node.js)

Le backend utilise l'IP publique pour produire les messages.

Problème : Timeout de connexion initial.

Résolution : Configuration de la retry-policy et du timeout à 30s.
brokers: ['34.78.144.120:9092'],
connectionTimeout: 30000,



4. Niveau 3 : Traitement Spark (Cluster Dataproc)

Résolution des problèmes de ressources

Initialement, le cluster échouait avec l'erreur Initial job has not accepted any resources.
Solution finale : Création d'un nouveau cluster plus robuste pour supporter la charge combinée de Jupyter et Spark.

Spécifications du cluster fonctionnel :

- **Master** : n1-standard-4 (4 vCPU, 15 Go RAM).
- **Workers** : 2 nœuds n1-standard-2.
- **Réseau** : Utilisation de l'**IP Interne** (10.132.0.3) pour la communication Spark-Kafka.

Commande Spark-Submit (Ligne de commande)

C'est la méthode qui a permis de contourner les blocages de session dans JupyterLab :

```
spark-submit --packages org.apache.spark:spark-sql-kafka-0-10_2.12:3.5.0  
--master yarn --deploy-mode client spark_analytics.py
```



SSH dans votre navigateur

↑ IMPORTER UN FICHIER

↓ TÉLÉCHARGER LE FICHIER



Batch: 14

type	guestId	timestamp	url	payload	event_time
SEARCH	c8090655-7d0d-4c6...	2026-01-03T02:03:...	/results/	{"query":"","cate...	2026-01-03 02:03:...

Batch: 15

type	guestId	timestamp	url	payload	event_time
PRODUCT_CLICK	c8090655-7d0d-4c6...	2026-01-03T02:03:...	/results/	{"productId":"d36...	2026-01-03 02:03:...

Batch: 16

type	guestId	timestamp	url	payload	event_time
ADD_TO_CART_MODAL	c8090655-7d0d-4c6...	2026-01-03T02:03:...	/results/	{"productId":"d36...	2026-01-03 02:03:...

```
26/01/03 02:03:35 INFO GoogleHadoopOutputStream: hflush(): No-op due to rate limit (RateLimiter[stableRate=0.2qps]): readers will *not* yet see flushed data for gs://dataproc-temp-europe-west2-402761413082-2ca0pp8u/fa5e4d94-eef8-43e9-94c0-6f05c3daba01/spark-job-history/application_1767303275523_0002.inprogress [CONTEXT ratelimit_period="1 MINUTES [skip ped: 170]" ]
26/01/03 02:04:35 INFO GoogleHadoopOutputStream: hflush(): No-op due to rate limit (RateLimiter[stableRate=0.2qps]): readers will *not* yet see flushed data for gs://dataproc-temp-europe-west2-402761413082-2ca0pp8u/fa5e4d94-eef8-43e9-94c0-6f05c3daba01/spark-job-history/application_1767303275523_0002.inprogress [CONTEXT ratelimit_period="1 MINUTES [skip
```

5. Niveau 4 : Data Lake (Google Cloud Storage)

Format Parquet et Partitionnement

Les données sont écrites dans GCS avec les optimisations suivantes :

- **Format** : Parquet (Stockage colonnaire compressé).
- **Partitionnement** : `partitionBy("type")` crée des sous-dossiers par type d'événement.

```
# Extrait du code de stockage
query = events.writeStream \
    .format("parquet") \
    .option("path", "gs://tp-bigdata-datalake/data/web_events") \
    .option("checkpointLocation", "gs://tp-bigdata-datalake/checkpoints/") \
    .partitionBy("type") \
    .start()
```

The screenshot shows the Google Cloud Storage console. The left sidebar contains navigation options like 'Présentation', 'Buckets', 'Surveillance', 'Paramètres', 'Storage Intelligence', 'Ensembles de données In...', 'Configuration', 'Marketplace', and 'Notes de version'. The main area displays 'Informations sur le bucket' for 'tp-bigdata-datalake'. The 'Objet' tab is active, showing a directory tree. The 'web_events/' directory is expanded, revealing several subdirectories. The right pane shows a list of objects within the 'type=PAGE_VIEW' directory, including files like 'part-00000-130b5de9-f264-45a1-8...' and 'part-00000-969631c5-47c4-4a50-...'.

6. Problèmes Rencontrés et Solutions

Problème	Cause	Solution
Failed to find data source: kafka	Connecteur JAR absent.	Ajout de --packages dans le spark-submit.
Bad Gateway 502 (Jupyter)	Surcharge RAM du Master.	Augmentation du type de machine vers n1-standard-4.
No resources accepted	Conflit entre Jupyter et Spark.	Arrêt des kernels Jupyter et redimensionnement du cluster.
Connexion Kafka échouée	IP Interne vs Externe.	advertised.listeners sur IP publique pour Node.js, mais IP privée pour Spark.

7. Conclusion

Le système est désormais stable et scalable. Les données capturées sont archivées de manière structurée dans le Data Lake, prêtes pour être analysées via BigQuery ou utilisées pour entraîner des modèles de recommandation.